

Fastbook 02

Medición de Eficacia Publicitaria

Conceptos clave sobre
marketing mix modeling



02. Conceptos clave sobre marketing mix modeling

En el primer fastbook de esta asignatura revisamos qué significa el ROI y qué métodos existen para medirlo. Hay varios enfoques que destacan sobre el resto: marketing mix modeling (MMM), multitouch attribution (MTA) y experimentos (EXP).

En los siguientes fastbooks nos centraremos en el primer enfoque, es decir, marketing mix modeling (MMM). En particular, empezaremos haciendo una introducción al MMM y conceptos clave. Continuaremos con algunos ejemplos de aplicación de modelos de regresión para el cálculo del ROI y hablaremos sobre los componentes de una serie temporal. Terminaremos revisando cómo ha evolucionado este tipo de enfoque a lo largo del tiempo.

Por tanto, el objetivo de este fastbook es familiarizarnos con los principales términos que se emplean en esta tipología de medición y sentar la base teórica antes de continuar profundizando en este contenido a lo largo de la asignatura.

Autor: Carlos Real Ugena

[Introducción al marketing mix modeling](#)

[Modelos de regresión](#)

[Componentes de una serie temporal](#)

[Evolución del MMM](#)

Lesson 1 of 4

Introducción al marketing mix modeling

 Edix Educación

Recordemos que marketing mix modeling (MMM) hace referencia a una metodología de **medición de la eficacia publicitaria** basada en la construcción de modelos de series temporales que sirven para estimar la contribución del marketing y otros drivers en el negocio. Es un enfoque estratégico que nos servirá para estimar el retorno de la inversión (ROI).

MMM nos permite responder a preguntas que se hará el director de marketing de una compañía como las siguientes:

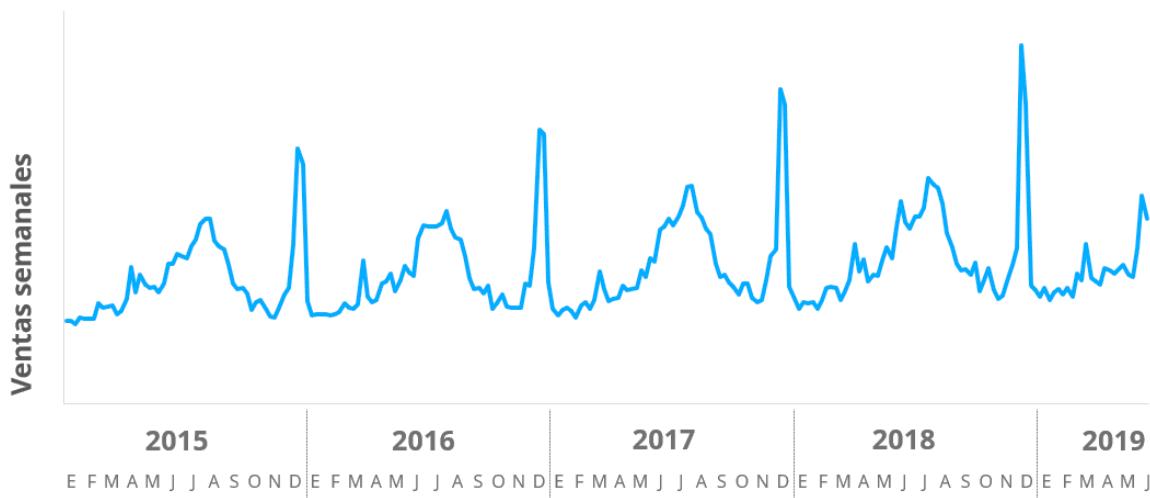
- ¿Cuánto contribuye la publicidad en la generación de negocio?
 - ¿Cómo afectaría a las ventas un incremento o reducción de la inversión publicitaria?
 - ¿Es más rentable invertir en televisión o en radio?
-

El marketing mix modelling es una técnica de modelado estadístico de series temporales que es utilizada para identificar la relación entre la inversión en marketing en cada canal y los resultados obtenidos por el mismo (ya sea en términos de visitas a la web, ventas, adquisición de clientes u otros KPI).

Por lo tanto, lo primero que vamos a necesitar para aplicar esta técnica es contar con **series temporales**.

En estadística, una serie temporal o cronológica es una secuencia de datos, observaciones o valores, medidos en determinados momentos del tiempo, ordenados cronológicamente y, normalmente, espaciados entre sí de manera uniforme.

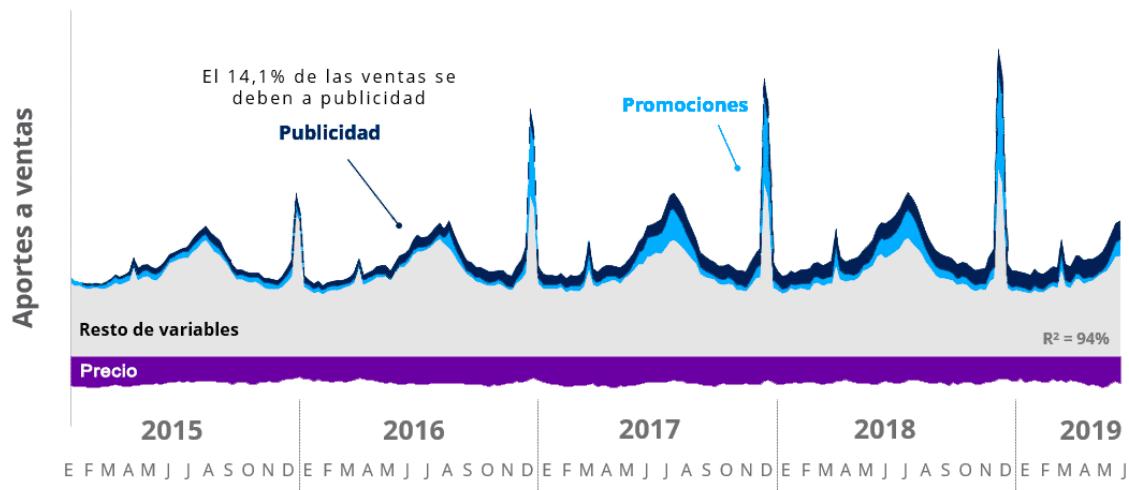
Normalmente, trabajaremos con series temporales diarias, semanales, mensuales o anuales. A continuación, un ejemplo gráfico de una serie temporal semanal que representa la evolución de ventas de un producto entre 2015 y 2019.



Cuando trabajemos con el enfoque de marketing mix modeling buscaremos explicar a qué se deben cada una de las subidas y bajadas de la serie temporal que estemos analizando, midiendo el aporte de las acciones de marketing y aislando efectos exógenos o que no depende de la estrategia llevada a cabo por el anunciante como la estacionalidad, inversión de la competencia, situación de la economía...

Si pensamos que el gráfico visto previamente representa las ventas de un producto de alimentación, el enfoque de marketing mix modeling nos ayudará a **estimar la contribución de la publicidad** y otros drivers a las ventas siempre que contemos con información histórica. Como principal resultado, tendremos el desglose de contribución de cada driver como si de un ‘puzzle’ se tratara.

A continuación, un ejemplo de cómo se descompondrían las ventas en **áreas positivas** (variables que tienen relación directa con las ventas) y **áreas negativas** (variables que tienen relación inversa con las ventas, es decir, un aumento de ellas produce una bajada en las ventas):



Por tanto, como hemos visto, el primer requisito para aplicar esta técnica es disponer de información histórica. A partir de los datos históricos podremos **aplicar diversas técnicas de regresión** que estimen la contribución de cada variable. Por lo tanto, solo podremos aplicar este tipo de modelo si nuestras inversiones en marketing fluctúan a lo largo del periodo a modelizar y hemos ido almacenando dicha información.

A continuación, vamos a terminar esta lección con un listado de cinco factores determinantes para poder aplicar esta metodología.

Es fundamental contar con **información suficiente tanto en cantidad como en calidad** para poder identificar correctamente las variaciones de la variable de negocio que queremos explicar.

Los datos deben contener el **menor número posible de errores o imprecisiones** para que los resultados se acerquen lo máximo posible a la realidad.

Será necesario tener recogidos también **factores externos** que puedan afectar a las series bajo análisis. Si un competidor ha comenzado una guerra de precios acompañándola de publicidad, debemos tenerlo en cuenta a la hora de desarrollar la modelización.

En cuanto a las variables de publicidad, tenemos que contar con **información sobre el número de impactos** (GRPs de nuestro spot de televisión, número de personas impactadas por un banner, etc.), así como información sobre la **inversión realizada en cada momento**.

Será necesario pensar en el **uso que se va a dar a la modelización para determinar la mejor metodología**. En general, vamos a preferir modelos explicativos a modelos puramente predictivos, dado que estaremos interesados en saber por qué han sucedido las cosas de una determinada forma, es decir, variables que han hecho ganar o perder negocio a lo largo del tiempo.

Lesson 2 of 4

Modelos de regresión

X Edix Educación

El siguiente concepto del que vamos a hablar es el de modelo de regresión y su aplicación en los modelos de marketing mix.

Un modelo de regresión es un modelo matemático que busca determinar la relación entre una variable dependiente (Y) respecto a una o varias variables, llamadas explicativas o independientes (X).

Con este tipo de modelos, buscamos estimar cuál será el impacto sobre la variable Y ante un cambio en las variables explicativas (X). Cabe señalar que cuando tenemos en cuenta solo una variable independiente hablamos de regresión lineal simple. En cambio, si se incluyen más factores, estamos ante un caso de regresión lineal múltiple.

Los modelos de regresión son empleados en diversos ámbitos (biología, finanzas, logística, etc.). En nuestro caso, vamos a estar interesados en aplicar **modelos de regresión múltiple a series temporales** con el objetivo de estimar la influencia de cada variable independiente en la variable dependiente que estemos explicando.

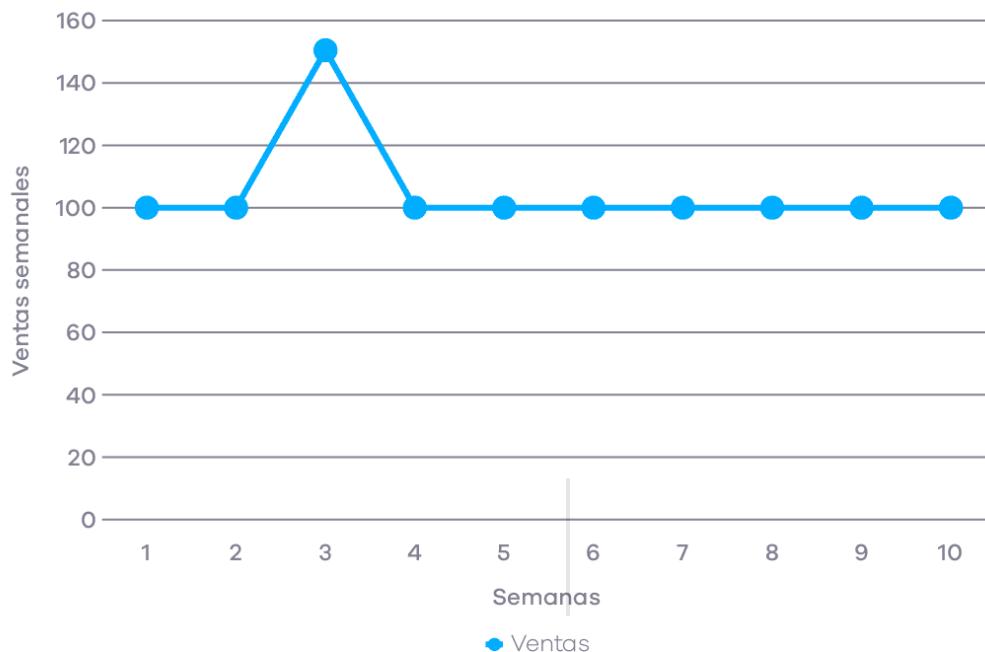
A continuación, vamos a ver un ejemplo muy sencillo sobre cómo podemos estimar el retorno de una inversión publicitaria a través de un modelo de regresión, simplificando la realidad y considerando que es el único factor que afecta a las ventas.

Pensemos que somos el responsable de marketing analytics de una compañía de automoción y tenemos que estimar el retorno generado por una campaña de publicidad llevada a cabo y en la que se han invertido 200.000€.

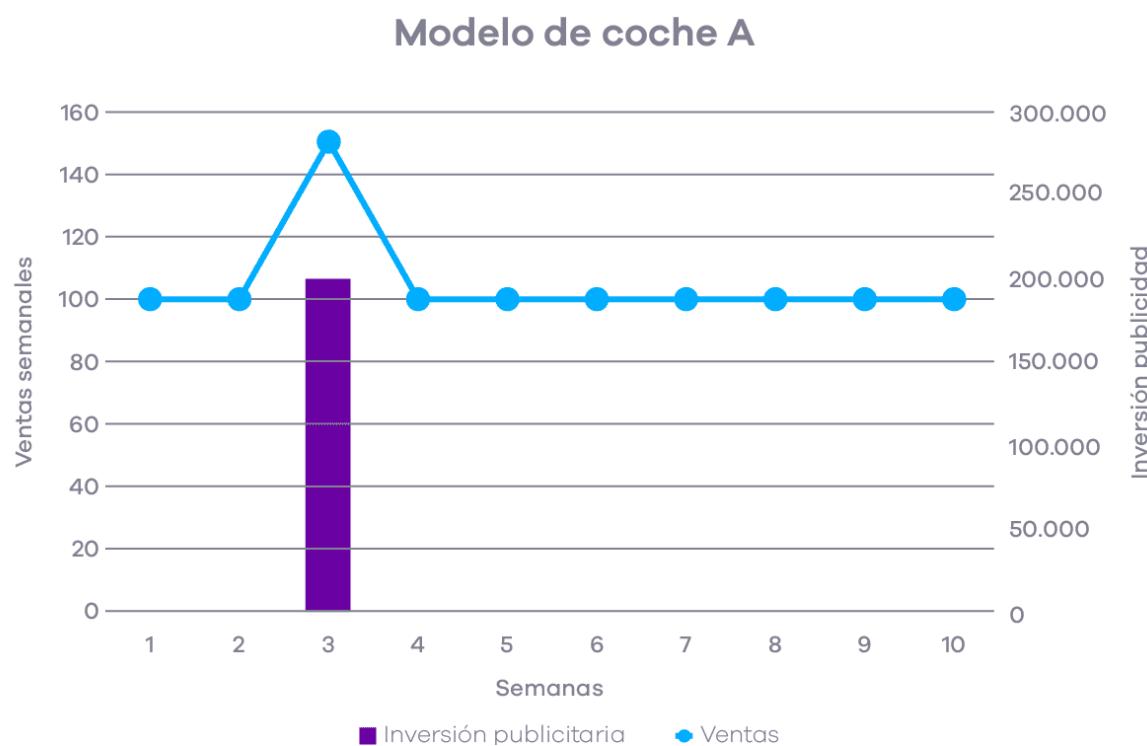


Para ello, un equipo interno nos proporciona la serie de ventas semanal del modelo de coche A (producto anunciado en la campaña), es decir, el número de coches vendidos para cada una de las semanas:

Modelo de coche A



En resumen, las ventas de todas las semanas han sido 100, excepto la tercera semana que las ventas han llegado a ser de 150, justamente la semana en la que se ha realizado la inversión. Representamos la inversión publicitaria en el eje secundario:



Ahora podemos ajustar un modelo de regresión simple que estime la contribución de la inversión a las ventas. Los datos representados previamente están recogidos en la siguiente tabla:

Semanas	Ventas	Inversión publicitaria
1	100	0
2	100	0
3	150	200.000
4	100	0
5	100	0
6	100	0
7	100	0
8	100	0
9	100	0
10	100	0

Por lo tanto, vamos a explicar nuestra variable dependiente ('Ventas') con la única variable independiente ('Inversión publicitaria') que tenemos. Para ello, vamos a poder utilizar R, Python o directamente Excel. En nuestro caso, emplearemos Excel para desarrollar este análisis sencillo. Para ello, seleccionamos data analysis en el módulo data y, posteriormente, la funcionalidad 'Regression':

The screenshot shows a Microsoft Excel window titled 'Ejemplos Reales para FastBooks.xlsx'. The 'Data' tab is selected in the ribbon. A blue circle highlights the 'Data Analysis' button in the 'Analysis' group. The main worksheet contains a table with columns 'Semanas', 'Ventas', and 'Inversión publicitaria'. Below the table, the 'Data Analysis' dialog box is open, with 'Regression' highlighted in the 'Analysis Tools' list. Other options include Histogram, Moving Average, Random Number Generation, Rank and Percentile, Sample, t-Test: Paired Two Sample for Means, t-Test: Two-Sample Assuming Equal Variances, t-Test: Two-Sample Assuming Unequal Variances, and z-Test: Two Sample for Means.

Semanas	Ventas	Inversión publicitaria
1	100	€0
2	100	€0
3	150	€200,000
4	100	€0
5	100	€0
6	100	€0
7	100	€0
8	100	€0
9	100	€0
10	100	€0

Lo siguiente será definir el conjunto de entrada para lanzar el modelo. Completamos el input Y e input X con la información de ventas e inversión publicitaria, respectivamente, y seleccionamos la opción Labels que considerará que la primera fila es la referente a las etiquetas de las variables. Además, seleccionamos el output Range, celda en la que obtendremos nuestro resultado (en nuestro caso en la celda F2 del libro) como se muestra en la imagen siguiente:

Semanas	Ventas	Inversión publicitaria
1	100	€0
2	100	€0
3	150	€200,000
4	100	€0
5	100	€0
6	100	€0
7	100	€0
8	100	€0
9	100	€0
10	100	€0
11	100	€0
12	100	€0

The screenshot shows an Excel spreadsheet titled "Ejemplos Reales para FastBooks.xlsx". The data is organized into several sections:

- Data Input:** Rows 1-11 show a table with columns "Semanas" (Weeks), "Ventas" (Sales), and "Inversión publicitaria" (Advertising Investment). The data points are: (1, 100, €0), (2, 100, €0), (3, 150, €200,000), (4, 100, €0), (5, 100, €0), (6, 100, €0), (7, 100, €0), (8, 100, €0), (9, 100, €0), (10, 100, €0).
- SUMMARY OUTPUT:** This section contains the following statistics:

	Regression Statistics
Multiple R	1
R Square	1
Adjusted R Square	1
Standard Error	1.0261E-14
Observations	10
- ANOVA:** This section shows the ANOVA table:

	df	SS	MS	F	Significance F
Regression	1	2250	2250	2.13699E+31	5.3704E-123
Residual	8	8.42306E-28	1.05288E-28		
Total	9	2250			
- Coefficients:** This section displays the regression coefficients:

	Coefficients	Standard Error	t Stat	P-value	Lower 95%	Upper 95%	Lower 95.0%	Upper 95.0%
Intercept	100	3.42034E-15	2.92369E+16	2.0978E-129	100	100	100	100
Inversión publicitaria	0.00025	5.40803E-20	4.62276E+15	5.3704E-123	0.00025	0.00025	0.00025	0.00025

¿Cómo interpretamos el resultado del modelo?

- El ajuste que obtenemos con nuestro modelo es perfecto. El R² y R² ajustado (celdas G6 y G7) son del 100%. Esto nunca ocurrirá en la realidad, pero recordemos que estamos ante un ejemplo inventado simple en el que hemos supuesto que las ventas son similares a lo largo del tiempo y solo varían cuando hay una campaña de publicidad.
- El intercept (intercepto o nivel base en español) recogido en la celda G18 toma un valor positivo de 100. Como ya vimos visualmente, en una semana normal se producen 100 ventas del modelo de coche A. Además, el p-value (p-valor) es muy bajo y nos indica que esta variable es significativa en el modelo.

- Y el resultado que más nos interesa está recogido en la fila 19. El coeficiente de la variable de inversión publicitaria es de 0,00025 (celda G19). Este valor nos indica que por cada euro invertido se obtienen 0,00025 ventas, es decir, se venden 0.00025 coches. Dado que es un número pequeño, decidimos multiplicarlo por 100.000, de manera que obtendremos las ventas de coches por cada 100.000€ de inversión. En nuestro caso, tendríamos que por cada 100.000€ de inversión vendemos 25 coches. Es decir, hemos empleado nuestro modelo de regresión para calcular el ROI de la siguiente forma:

$$ROI = \frac{\text{Retorno}}{\text{Inversión}} \times 100.000\text{€} = 25$$

- Cabe destacar que el p-valor es también muy bajo en este caso (celda J) lo cual nos está indicando que la **variable de inversión es significativa** en la generación de ventas.
- Si quisiéramos calcular el retorno monetario tendríamos que estimar la ganancia media que supone cada coche, teniendo en cuenta su precio y el coste de producirlo.

En el caso anterior, no habría sido necesario utilizar un modelo de regresión para hacer esta estimación, ya que a la vista de los primeros gráficos era muy sencillo estimar el negocio incremental generado por la publicidad. Ha sido únicamente un ejemplo para ilustrar la metodología, pues todos sabemos que **las ventas de una compañía fluctuarán a lo largo del tiempo** y estarán influenciadas por diversos factores que habrá que analizar.

En la ‘vida real’ tendremos que ser capaces de considerar las variables que puedan estar afectando al negocio e ir testándolas en un proceso iterativo.

Hemos empleado la metodología de regresión lineal simple. Sin embargo, ¿qué ocurriría si hubiéramos tenido dos campañas en el pasado que queremos evaluar? Sería necesario construir un modelo de regresión múltiple.

Utilicemos el mismo ejemplo que antes, pero introduciendo una nueva campaña durante la semana 7 de 500.000€ con el correspondiente incremento en ventas:

Modelo de coche A



Seguimos el mismo proceso que antes, seleccionando en este caso dos variables independientes en el input X range referentes a las inversiones de las dos campañas de publicidad:

The screenshot shows a Microsoft Excel window titled 'Ejemplos Reales para FastBooks.xlsx'. The 'Data' tab is selected in the ribbon. A 'Regression' dialog box is open over the spreadsheet. The 'Input Y Range' is set to \$C\$2:\$C\$12 and the 'Input X Range' is set to \$D\$2:\$E\$12. The 'Labels' checkbox is checked. The 'OK' button is highlighted.

Semanas	Ventas	Inversión Campaña 1	Inversión Campaña 2
1	100	€0	€0
2	100	€0	€0
3	150	€200,000	€0
4	100	€0	€0
5	100	€0	€0
6	100	€0	€0
7	200	€0	€500,000
8	100	€0	€0
9	100	€0	€0
10	100	€0	€0

En este caso, hemos lanzado un modelo de regresión múltiple que nos da la siguiente salida:

The screenshot shows a Microsoft Excel window titled 'Ejemplos Reales para FastBooks.xlsx'. The 'Data' tab is selected in the ribbon. The results of a regression analysis are displayed in several tables:

- SUMMARY OUTPUT** table:

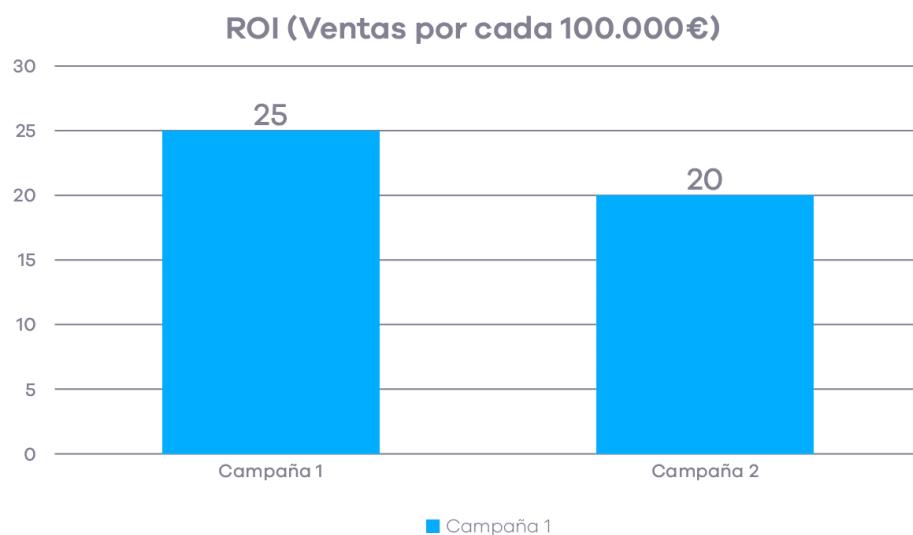
Multiple R	1
R Square	1
Adjusted R Square	1
Standard Error	1.5656E-15
Observations	10
- ANOVA** table:

	df	SS	MS	F	Significance F
Regression	2	10250	5125	2.09089E+33	1.919E-115
Residual	7	1.71577E-29	2.4511E-30		
Total	9	10250			
- Coefficients** table:

	Coefficients	Standard Error	t Stat	P-value	Lower 95%	Upper 95%	Lower 95.0%	Upper 95.0%
Intercept	100	5.53523E-16	1.80061E+17	4.2046E-119	100	100	100	100
Inversión Campaña 1	0.00025	8.30285E-21	3.01101E+16	1.177E-113	0.00025	0.00025	0.00025	0.00025
Inversión Campaña 2	0.0002	3.32114E-21	6.02203E+16	9.1955E-116	0.0002	0.0002	0.0002	0.0002

Interpretemos de nuevo los resultados:

- Obtenemos un ajuste perfecto, las tres variables independientes ('Intercept', 'Inversión Campaña 1' e 'Inversión Campaña 2') son positivas y el p-valor es muy bajo lo que nos garantiza la contribución de las campañas a las ventas.
- En este caso, podemos observar que el coeficiente de la 'Inversión Campaña 2' es ligeramente menor que el de la 'Inversión Campaña 1', lo que nos está indicando que, por cada euro de inversión, la 'Campaña 2' genera menor volumen de ventas que la 'Campaña 1'. Si hacemos el mismo cálculo que en el caso anterior del ejemplo, podemos estimar las ventas generadas por cada euro de inversión. Representamos en el siguiente gráfico el resultado de cada campaña en ROI:



- En resumen, la 'Campaña 1' ha alcanzado un retorno mayor a pesar de que las ventas durante la 'Campaña 2' hayan sido más altas. Como ya hemos visto previamente, el denominador de la fórmula del ROI es la inversión y la 'Campaña 2' ha tenido una inversión muy superior a la 'Campaña 1', sin ser capaz de generar un incremento en ventas proporcional a dicha inversión.

Acabamos de completar nuestro primer ejemplo de modelización de marketing mix modeling con un caso muy trivial que sirve para entender lo que buscaremos en casos más complejos, en los que tengamos series de negocio que dependan de múltiples factores.

Lesson 3 of 4

Componentes de una serie temporal

X Edix Educación

Hasta ahora, hemos revisado dos conceptos clave en este tipo de mediciones: definición de serie temporal y aplicación de modelo de regresión múltiple para estimar el retorno publicitario. Cuando trabajamos con series temporales, debemos tener en cuenta los **componentes en los que se pueden dividir**.

Los **componentes de una serie temporal** son los siguientes:

Tendencia (T) —

Indica la evolución general y persistente del fenómeno observado, es un componente de la serie que refleja la evolución a largo plazo.

Variación estacional (S) —

Es el movimiento periódico producido a corto plazo. Se trata de una componente debida a la influencia de ciertos fenómenos que se repiten de manera periódica en un año (las estaciones), una semana (los fines de semana) o un día (las horas punta) o cualquier otro periodo.

Fluctuación cíclica (C) —

Componente de la serie que recoge las oscilaciones periódicas de amplitud superior a un año. Son movimientos normalmente irregulares alrededor de la tendencia (ciclos).

Error (E) —

Variación aleatoria, de carácter errático, también denominada residuo. No muestra ninguna regularidad, debido a fenómenos de carácter ocasional como pueden ser tormentas, terremotos, inundaciones, huelgas, guerras, avances tecnológicos, etc.

Pensemos en un caso real y veamos cómo afectarían los componentes de una serie temporal a la modelización. Imaginemos que queremos explicar las ventas diarias de billetes de una aerolínea en España por el canal móvil. Sin duda, los componentes de la serie temporal jugarán un papel fundamental en la modelización.

Tendencia

Debemos considerar que habrá una tendencia creciente debido al comportamiento de los usuarios. Si disponemos de algún dato, como la penetración del móvil en las compras en el sector de viajes, podremos utilizar dicha variable para aislar ese efecto. Si no disponemos de esa información, tendremos que estimar el crecimiento que no se debe a otros factores.

Variación estacional

El comportamiento diario y mensual será distinto. Por ejemplo, existirá un comportamiento distinto entre días de la semana, durante los fines de semana, durante los festivos o durante las semanas previas al verano, Navidad y Semana Santa. Esto nos obligará a construir variables que aislen cada uno de los efectos estacionales.

Fluctuación cíclica

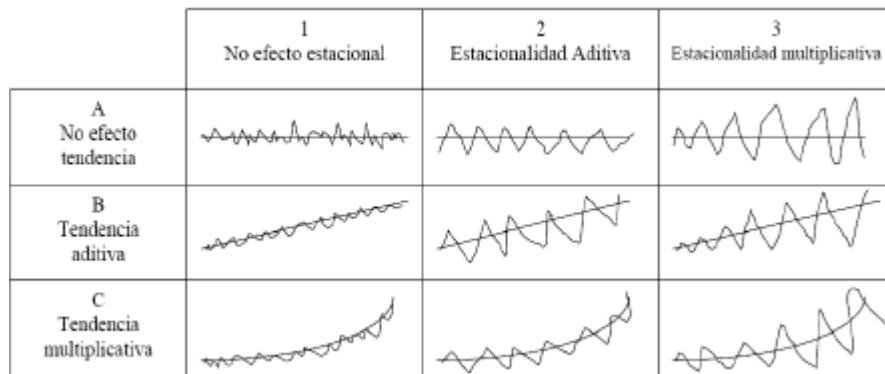
Si modelizamos un periodo de tiempo largo, tendremos que considerar comportamientos cíclicos relacionados con la economía. Variables como la tasa de paro o el PIB pueden ayudarnos a aislar estos comportamientos cíclicos.

Error

A medida que vayamos estimando nuestro modelo observaremos comportamientos que no somos capaces de explicar. Por ejemplo, el anunciante podría haber tenido un problema en la web móvil durante varias horas un día y que eso esté afectando al volumen de ventas de ese día, pero que esa información no esté disponible. Cuando ajustemos nuestro modelo, veremos que ese día se ha producido un menor número de ventas de las esperadas, pero no seremos capaces de explicarlo con las variables disponibles y ese desajuste será el error que cometemos. En otros casos, el error nos dará información relevante para identificar variables que no hemos considerado en la modelización. Si nuestro periodo a modelizar incluyera 2020 y no testamos ninguna variable referente al Covid, veremos que el error cometido a partir de marzo es muy alto y nos indicará que tenemos que incorporar información referente a este evento o eliminar dichos días en la modelización.

El conocimiento del negocio y compañía a modelizar, junto con el análisis inicial de la información nos permitirá decidir cómo trabajar con cada uno de los componentes vistos previamente y qué variables introducir para reflejar de la mejor manera posible la tendencia, estacionalidad, fluctuación cíclica y error.

Hay que tener en cuenta que la combinación de componentes puede dar lugar a series temporales con **comportamientos muy diferenciados** como los recogidos en la clasificación de Pegel de 1969:



[Clasificación de Pegel de 1969.](#)

Si pensamos en las ventas de helados, será indispensable aislar la componente estacional del verano para poder atribuir de manera correcta el resto de los drivers (palancas) que afecten a las ventas.

Evolución del MMM

X Edix Educación

Por último, daremos un breve repaso a la historia del marketing mix modeling.

1

El término marketing mix fue utilizado por Neil Borden, profesor de publicidad en Harvard, por primera vez en 1949. Lo mencionó en el artículo [The Concept of the Marketing Mix](#).

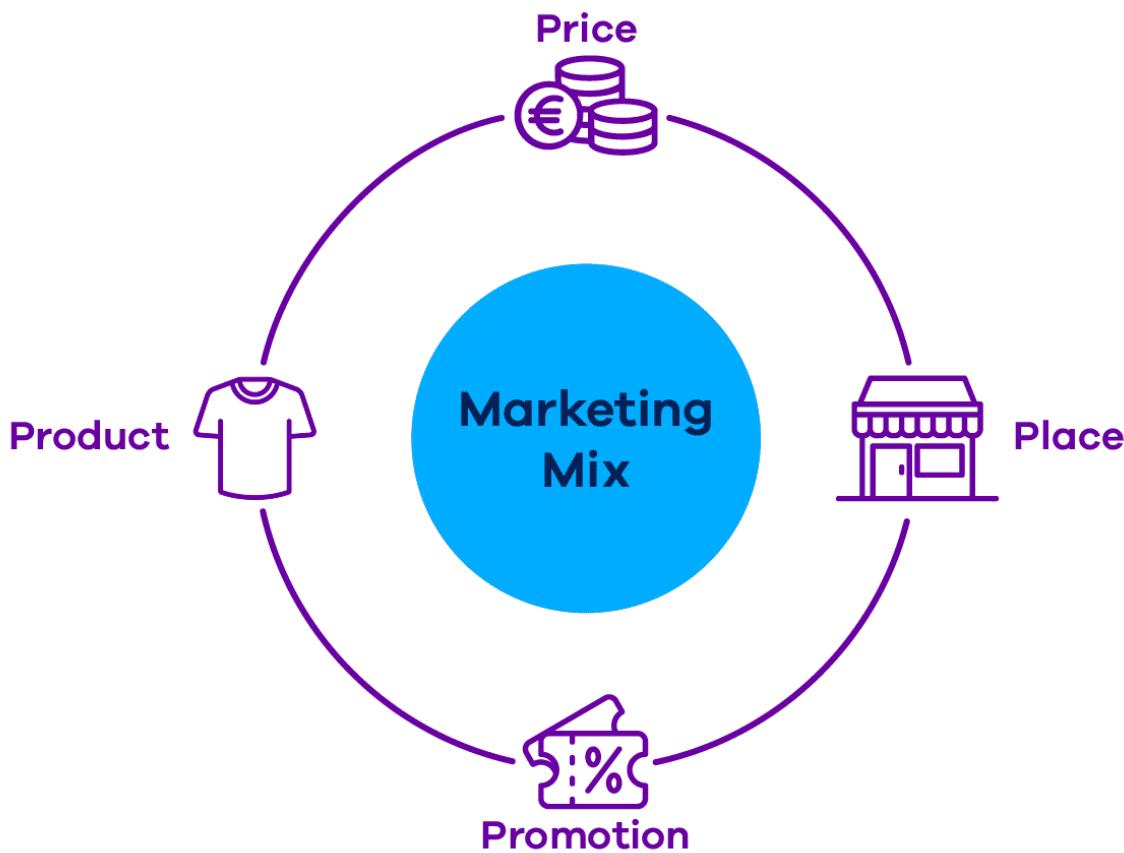
“Un responsable de marketing es un mezclador de ingredientes, que a veces utiliza una receta sobre la marcha, a veces adapta una receta a los ingredientes inmediatamente disponibles y, a veces, experimenta o inventa ingredientes que nadie más ha probado antes.”

- Neil Borden.

Además, intentó trasladar la idea de que una persona encargada de la estrategia de marketing de una compañía tiene que hacer un trabajo complicado de mezclar (mix) los elementos del marketing para que se adapten a las necesidades de su compañía.

2

Posteriormente, Jerome McCarthy fue la primera persona en hablar sobre las **cuatro P's del marketing: precio, promoción, producto y distribución** como las variables principales en la elaboración de un marketing mix.



3

Por su parte, la metodología de **marketing mix modeling** se hizo popular entre **1960 y 1970**, cuando el panorama de marketing era más simplificado que el actual y los medios masivos (televisión, radio...) suponían la mayor parte de la inversión en publicidad.

4

Kraft fue una de las primeras empresas en beneficiarse de esta metodología. Cuando lanzaron Jell-O, un producto de gelatina, pudieron elegir entre varias cadenas de televisión y publicidad en revistas para promocionar el nuevo producto. El enfoque del MMM tradicional les permitió analizar el impacto en ventas en diferentes partes del país y épocas del año testando distintos niveles de inversión. Por ejemplo, anunciaron la gelatina en diez ciudades durante diez semanas para medir cómo aumentaban las ventas. Esto es MMM en su forma más simple, pero un buen ejemplo de cómo surgió esta metodología.

5

Durante los últimos años, el **MMM** ha evolucionado muy rápido tal y como podemos ver en el siguiente diagrama:



En resumen

El mercado publicitario está cada vez **más fragmentado** con multitud de canales debido al surgimiento de la publicidad online, existe mayor volumen de datos fiables y los métodos han ido avanzando gracias a nuevos desarrollos analíticos.

En la actualidad, las compañías se encuentran principalmente ante **tres retos**:

Automatización

Actualización ágil de la información que nutre los modelos de marketing mix y que aceleren la toma de decisión desde la recogida de datos.

Escalabilidad —

Ampliación de modelos a nuevos productos y/o regiones y que den un nivel de aprendizajes más granular.

Aprendizaje automático —

Aplicación de metodologías de aprendizaje automático (machine learning) que permiten captar mejor la influencia de cada variable y que facilitan la actualización de modelos.

Para terminar, unas palabras de John Wanamaker, uno de los primeros impulsores del uso intensivo de la publicidad: “La mitad del dinero que me gasto en publicidad es un desperdicio: el problema es que no sé qué mitad es”.

Los profesionales del marketing necesitan de metodologías que les permitan entender cuál es esa mitad y el marketing mix modeling es una de esas formas.

¡Enhorabuena! Fastbook superado

edix

Creamos Digital Workers